1 BeschreibendeStatistik

1.1 Begriffe

]

1.1.1 Beschreibende/Deskriptive Statistik

Beobachtete Daten werden durch geeignete statistische Kennzahlen charakterisiert und durch geeignete Grafiken anschaulich gemacht.

1.1.2 Schließende/Induktive Statistik

Aus beobachtete Daten werden Schlüsse gezogen und diese im Rahmen vorgegebener Modelle der Wahrscheinlichkeitstheorie bewertet.

1.1.3 Grundgesamtheit

Ω: Grundgesamtheit ω:Element oder Objekt der Grundgesamtheit diskret(<30 Ausprägungen), stetig(≥30 Ausprägungen), univariat(p=1), mulivariat(p>1)

1.2 Lagemaße

1.2.1 Modalwerte x_{mod}

Am häufigsten auftretende Ausprägungen (insbesondere bei **qualitativen** Merkmalen)

1.2.2 Mittelwert

R:$mean(x)$
Schwerpunkt der Daten.**Empfindlich**gegemüber Ausreißern.
$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} x_i$

1.3 Median

R:$median(x)$
Liegt in der Mitt der sortierten Daten x_i.
Unempfindlich gegenüber Ausreißern.

$$x_{0.5} = \begin{cases} x_{\frac{n+1}{2}}, \text{falls n ungerade} \\ \frac{1}{2}(x_{\frac{n}{2}} + x_{\frac{n}{2}+1}), \text{falls n gerade} \end{cases} \tag{1}$$

1.4 Streuungsmaße

1.4.1 Spannweite

max x_i - min x_i

1.4.2 Stichprbenverians s^2

R:$var(x)$
Verschiebungssatz:
$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x}^2) = \frac{1}{n-1}(\sum_{i=1}^{n} x_i^2 - n\overline{x}^2)$ Gemittelte Summe der quadratischen Abweichung vom Mittelwert

1.4.3 Stichprobenstandardabweichung

R:$sd(x)$
$s = \sqrt{s}$ Streuungsmaß mit gleicher Einheit wie beobachteten Daten x_i.$\overline{x}$ minimiert die "quadratische Verlustfunktionöder die Varianz gibt das Minimum der Fehlerquadrate an.

1.5 p-Quantile

R:$quantile(x,p)$. Teilt die **sortierten** Daten x_i ca. im Verhältnis p: (1-p) d.h. $\hat{F}(x_{(p)}) \approx p$ 1. Quartil = 0.25-Quantil; Median = 0.5-Quantil; 3. Quartil = 0.75-Quartil;

1.6 Interquartilsabstand I

$I = x_{0.75} - x_{0.25}$. Ist ein weiterer Streuungsparameter.

1.7 Chebyshev

$\frac{N(S_k)}{n} > 1 - \frac{1}{k^2}$, für alle k ≥ 1 $\overline{x}$ der Durchschnitt, s > 0 die Stichproben-Standardabweichung von Beobachtungswerten $x_1,...,x_n$. Sei $S_k = \{i, 1 \leq i \leq n : |x_i - \overline{x}| < k \cdot s\}$; Für eine beliebige Zahl k ≥ 1 liegen mehr als $100 \cdot (1 - \frac{1}{k^2})$ Prozent der Daten im Intervall von $\overline{x} - ks$ bis $\overline{x} + ks$. **Speziell:**Für k = 2 liegen mehr als 75% der Daten im 2s-Bereich um $\overline{x}$. Für k=3 liegen mehr als 89% der Daten im 3s-Bereich um $\overline{x}$. **Komplement Formulierung:** $\overline{S}_k = \{i||x_i - \overline{x}| \geq k \cdot s\}$; $\frac{N(\overline{S}_k)}{n} \leq \frac{1}{k^2}$;
Die Ungleichheit lifert nur eine **sehr grobe Abschätzung**, ist aber unabhängig von der Verteilung der Daten. **Empirische Regeln** 68% der Daten im Bereich um $\overline{x} \pm s$. 95% um $\overline{x} \pm 2s$. 99.7% um $\overline{x} \pm 3s$.

1.8 Korrelation

Grafische Zusammenhang zwischen multivariaten Daten y und y durch ein Streudiagramm. Kennzahlen zur Untersuchung des Zusammenhangs:

1.8.1 Empirische Kovarians

R:$cov(x,y)$; $s_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y}) = \frac{1}{n-1}(\sum_{i=1}^{n}(x_i y_i - n\overline{xy})$

1.8.2 Empirische Korrellationskoeffizient r

R:$cor(x,x)$; $r = \frac{s_{xy}}{s_x x_y}$; Näherungsweise lin. Zusammenhang zw. x und y, falls |r| ≈1.

1.8.3 Regressionsgerade y

$y = mx + t$ mit $m = r \cdot \frac{s_y}{s_x}$ und $t = \overline{y} - m \cdot \overline{x}$

2 Wahrscheinlichkeitsrechnung

2.1 Begriffe

Ergebnisraum Ω: Menge aller möglichen Ergebnisse eines Experiments
Elementarereignis $\omega \in \Omega$: einzelnes Element von Ω
Ereignis$E \subseteq \Omega$: beliebige Teilmenge des Ergebnisraums Ω heißt sicheres Ereignis, $\emptyset$ heißt unmögliches Ereignis
Vereinigung $E \cup F$: Ereignis E oder Ereignis F treten ein. $\bigcup_{i=1}^{n} E_i$: mindestens ein Ereignis $E_i$tritt ein.
Schnitt $E \cap F$: Ereignis E und Ereignis F treten ein.
$\bigcap_{i=1}^{n} E_i$ alle Ereignisse E_i treten ein. **Gegenereignis** $\overline{E} = \Omega / E$: Ereignis E tritt nicht ein (Komplement von E)
Disjunkte EreignisseE und F: $E \cap F = \emptyset$

2.2 De Morgan'schen Regeln

$\overline{E_1 \cup E_2} = \overline{E}_1 \cap \overline{E}_2$
$\overline{E_1 \cap E_2} = \overline{E}_1 \cup \overline{E}_2$

2.3 Wahrscheinlichkeit

$0 \leq P(E) \leq 1$; P(Ω) = 1;
P($\bigcup_{i=1}^{\infty}$) = $\sum_{i=1}^{\infty}$ P(E_i), falls $E_i \cap E_j = \emptyset$ für $i \neq j$

2.3.1 Satz 2.1

P($\overline{E}$) = 1 -P(E)
P($E \cup F$) = P(E)+ P(F) - P($E \cap F$)
(Übungsaufgabe!!! Ergänzen)

2.4 Laplace-Experiment

Zufallsexperimente mit n gleich wahrscheinlichen Elementarereignissen. Dann berechnet sich die Wahrscheinlichkeit P(E) für $E \subseteq \Omega$ aus:
P(E) $= \frac{Anzahlder f rEgnstigenEreignisse}{AnzahldermglichenEreignisse} = \frac{MchtigkeitvonE}{Mchtigkeitvon\Omega} = \frac{|E|}{\Omega}$ **text**

2.5 Kombinatorik

2.5.1 Allgmeines Zählprinzip

Anzahl der Möglichkeiten für ein k-stufiges Zufallsexperiment mit n_i Varianten im i-ten Schritt: $n_1 \cdot n_2 \cdot ... \cdot n_k$

2.5.2 Permutationen

Anzahl einer n-elementigen Menge n-maliges Ziehen ohne Zurücklgen mit Beachtung der Reihenfolge: **n unterscheidbare Elemente**: $n! = n \cdot (n-1) textbf ...2 \cdot 1$
k Klassen mit je n_i **nicht unterscheidbaren Elementen** $n = sum_k^{i=1} n_i$: $\frac{n!}{n_1! \cdot n_2! \cdot ... \cdot n_k!}$

2.5.3 Anzahl k-elementigen Teilmengen einer n-elementigen Menge k-maliges Ziehen aus einer n-elementigen Menge

ohne Zurücklegen = $k \leq n$.
mit Zurücklegen = $k > n$ möglich.
mit Beachtung der Reihenfolge, ohne Zurücklegen: $\frac{n!}{(n-k)!}$
ohne Beachtung der Reihenfolge, ohne Zurücklegen: $\binom{n}{k} = \frac{n!}{(n-k)!k!}$
mit Beachtung der Reihenfolge, mit Zurücklegen: n^k
ohne Beachtung der Reihenfolge, mit Zurücklegen $\binom{n+k-1}{k}$

2.6 Bedingte Wahrscheinlichkeit

$P(E|F) = P_F(E) = \frac{|E \cap F|}{|F|} = \frac{P(E \cap F))}{P(F)}$

2.6.1 Satz 2.2

$P(E \cap F) = P(E|F) \cdot P(F)$
$P(E \cap F) = P(F|E) \cdot P(E)$

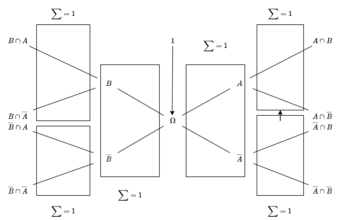

2.6.2 Satz der totalen Wahrscheinlichkeit

Sei $\Omega = \bigcup_{i=1}^{n} E_i$ mit $E_i \cap E_j = \varnothing$ für $i \neq j$ d.h. die Ereignisse bilde eine disjunkte Zerlegung bzw. eine Partition von Ω. Somit gilt:
$P(F) = \sum_{i=1}^{n} P(F \cap E_i) = \sum_{i=1}^{n} P(F|E_i) \cdot P(E_i)$
Summe der Äste des Wahrscheinlichkeitsbaums zu allen Schnitten $F \cap E_i$

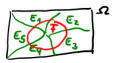

2.6.3 Vierfeldertafel

$P(F) = P(F \cap E) + P(F \cap \overline{E})$
$P(\overline{F}) = P(\overline{F} \cap E) + P(\overline{F} \cap E)$

	E	$\overline{E}$	
F	$P(F \cap E)$	$P(F \cap \overline{E})$	$P(F)$
$\overline{F}$	$P(\overline{F} \cap E)$	$P(\overline{F} \cap \overline{E})$	$P(\overline{F})$
	$P(E)$	$P(\overline{E})$	1

Satz 2.2 $P(E \cap F)P(E) \cdot P(F|E) = P(F) \cdot P(E|F)$ **Tafel** $= P(F) - P(F \cap \overline{E}) = P(E) - P(\overline{F} \cap E)$; $P(\overline{F}|E) = 1 - P(F|E)$

2.6.4 Formel von Bayes

Hilfreich, wenn man man $P(F|E_i)$ kennt, aber nicht $P(E_k|F)$ **Satz 2.4** $P(E_k|F) = \frac{P(F|E_k) \cdot P(E_k)}{\underbrace{\sum_{i=1}^{n} P(F|E_i) \cdot P(E_i)}}$
Nur Nenner!P(F) aus dem Satz der totalen Wahrscheinlichkeit.

2.6.5 Stochastische Unabhängigkeit

Uebung Die Ereignisse E und F heißen (stochastisch) unabhängig, wenn die Information über das Eintreten des einen Ereignisses die Wahrscheinlichkeit für das Eintreten des anderen Ereignisses nicht ändert, d.h. falls
$\underbrace{P(E|F)} = P(E) oder P(E \cap F) = P(E) \cdot P(F)$
$= \frac{P(E \cap F)}{P(F)}$
Es gilt Falls die Ereignisse E, F unabhängig sind, dann sind auch:

$E, \overline{F}$

$\overline{E}, F$

$\overline{E}, \overline{F}$ unabhängig **Bemerkung**

- Stochastische Unabhängigkeit bedeutet nicht notwendigerweise eine kausale Abhängigkeit
- Veranschaulichung mit Venn Diagramm 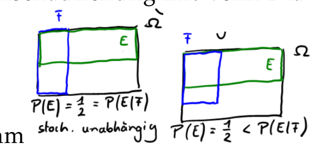

- $A, B \neq \varnothing$ und $A \cap B = \varnothing$
$P(A \cap B) \stackrel{?}{=} P(A) \cdot P(B)$
$\varnothing \neq P(A) \cdot P(B)$ da P(A) > 0 und P(B)> 0
=> A, B stochastisch abhängig