

1 Beschreibende/Deskriptive Statistik

1.1 Begriffe

Beobachtete Daten werden durch geeignete statistische Kennzahlen charakterisiert und durch geeignete Grafiken anschaulich gemacht.

1.1.1 Beschreibende/Deskriptive Statistik

Aus beobachtete Daten werden Schlüsse gezogen und diese im Rahmen vorgegebener Modelle der Wahrscheinlichkeitstheorie bewertet.

1.1.2 Schließende/Induktive Statistik

Aus beobachtete Daten werden Schlüsse gezogen und diese im Rahmen vorgegebener Modelle der Wahrscheinlichkeitstheorie bewertet.

1.2 Lagemaße

Am häufigsten auftretende Ausprägungen (insbesondere bei qualitativen Merkmalen)

1.2.1 Modalwerte  $x_{mod}$

Am häufigsten auftretende Ausprägungen (insbesondere bei qualitativen Merkmalen)

1.2.2 Mittelwert

$R: mean(x)$  Schwerpunkt der Daten. Empfindlich gegenüber Ausreißern.

1.3 Median

$R: median(x)$  Liegt in der Mitt der sortierten Daten  $x_i$ . Unempfindlich gegenüber Ausreißern.

1.4 Streuungsmaße

1.4.1 Spannweite

$\max x_i - \min x_i$

1.4.2 Stichprobenvarianz  $s^2$

$R: var(x)$  Verschiebungssatz:

$n\bar{x}^2$ ) Gemittelte Summe der quadratischen Abweichung vom Mittelwert

1.4.3 Stichprobenstandardabweichung

$R: sd(x)$   $s = \sqrt{s}$  Streuungsmaß mit gleicher Einheit wie beobachteten Daten  $x_i$ .  $\bar{x}$  minimiert die "quadratische Verlustfunktion" oder die Varianz gibt das Minimum der Fehlerquadrate an.

1.5 p-Quantile

$R: quantile(x, p)$ . Teilt die sortierten Daten  $x_i$  ca. im Verhältnis p: (1-p) d.h.  $\hat{F}(x_p) \approx p$ . Quartil = 0.25-Quantil; Median = 0.5-Quantil; 3. Quartil = 0.75-Quantil;

1.6 Interquartilsabstand I

$I = x_{0.75} - x_{0.25}$ . Ist ein weiterer Streuungsparameter.

1.7 Chebyshev

$\frac{N(S_k)}{n} > 1 - \frac{1}{k^2}$ , für alle  $k \geq 1$   $\bar{x}$  der Durchschnitt,  $s > 0$  die Stichproben-Standardabweichung von Beobachtungswerten  $x_1, \dots, x_n$ . Sei  $S_k = \{i, 1 \leq i \leq n : |x_i - \bar{x}| < k \cdot s\}$ ; Für eine beliebige Zahl  $k \geq 1$  liegen mehr als  $100 \cdot (1 - \frac{1}{k^2})$  Prozent der Daten im Intervall von  $\bar{x} - ks$  bis  $\bar{x} + ks$ . Speziell: Für  $k = 2$  liegen mehr als 75% der Daten im 2s-Bereich um  $\bar{x}$ . Für  $k = 3$  liegen mehr als 89% der Daten im 3s-Bereich um  $\bar{x}$ . Komplement Formulierung:  $\bar{S}_k = \{i || x_i - \bar{x}| \geq k \cdot s\}$ ;  $\frac{N(\bar{S}_k)}{n} \leq \frac{1}{k^2}$ ;

Die Ungleichheit liefert nur eine sehr grobe Abschätzung, ist aber unabhängig von der Verteilung der Daten. Empirische Regeln 68% der Daten im Bereich um  $\bar{x} \pm s$ . 95% um  $\bar{x} \pm 2s$ . 99.7% um  $\bar{x} \pm 3s$ .

1.8 Korrelation

Grafische Zusammenhang zwischen multivariaten Daten y und x durch ein Streudiagramm. Kennzahlen zur Untersuchung des Zusammenhangs:

1.8.1 Empirische Kovarians

$R: cov(x, y)$ ;  $s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n-1} (\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y})$

1.8.2 Empirische Korrelationskoeffizient r

$R: cor(x, x)$ ;  $r = \frac{s_{xy}}{s_x s_y}$ ; Näherungsweise lin. Zusammenhang zw. x und y, falls  $|r| \approx 1$ .

1.8.3 Regressionsgerade y

$y = mx + t$  mit  $m = r \cdot \frac{s_y}{s_x}$  und  $t = \bar{y} - m \cdot \bar{x}$

2.1 Begriffe

Ergebnisraum  $\Omega$ : Menge aller möglichen Ergebnisse eines Experiments

Elementarereignis  $\omega \in \Omega$ : einzelnes Element von  $\Omega$

Ereignis  $E \subseteq \Omega$ : beliebige Teilmenge des Ergebnisraums  $\Omega$  heißt sicheres Ereignis,  $\emptyset$  heißt unmögliches Ereignis

Vereinigung  $E \cup F$ : Ereignis E oder Ereignis F treten ein.  $\bigcup_{i=1}^n E_i$ : mindestens ein Ereignis  $E_i$  tritt ein.

Schnitt  $E \cap F$ : Ereignis E und Ereignis F treten ein.

$\bigcap_{i=1}^n E_i$  alle Ereignisse  $E_i$  treten ein. Gegenereignis  $\bar{E} = \Omega / E$ : Ereignis E tritt nicht ein (Komplement von E)

Disjunkte Ereignisse E und F:  $E \cap F = \emptyset$

2.2 De Morgan'schen Regeln

$\overline{E_1 \cup E_2} = \bar{E}_1 \cap \bar{E}_2$   
 $\overline{E_1 \cap E_2} = \bar{E}_1 \cup \bar{E}_2$

2.3 Wahrscheinlichkeit

$0 \leq P(E) \leq 1$ ;  $P(\Omega) = 1$ ;  
 $P(\bigcup_{i=1}^{\infty} E_i) = \sum_{i=1}^{\infty} P(E_i)$ , falls  $E_i \cap E_j = \emptyset$  für  $i \neq j$

2.3.1 Satz 2.1

$P(\bar{E}) = 1 - P(E)$   
 $P(E \cup F) = P(E) + P(F) - P(E \cap F)$  (Übungsaufgabe!!! Ergänzen)

2.4 Laplace-Experiment

Zufallsexperimente mit n gleich wahrscheinlichen Elementarereignissen. Dann berechnet sich die Wahrscheinlichkeit  $P(E)$  für  $E \subseteq \Omega$  aus:

$P(E) = \frac{\text{Anzahl der für E günstigen Ereignisse}}{\text{Anzahl der möglichen Ereignisse}} = \frac{\text{Mächtigkeit von } E}{\text{Mächtigkeit von } \Omega} = \frac{|E|}{|\Omega|}$  text

2.5 Kombinatorik

2.5.1 Allgemeines Zählprinzip

Anzahl der Möglichkeiten für ein k-stufiges Zufallsexperiment mit  $n_i$  Varianten im i-ten Schritt:  $n_1 \cdot n_2 \cdot \dots \cdot n_k$

2.5.2 Permutationen

Anzahl einer n-elementigen Menge n-maliges Ziehen ohne Zurücklegen mit Beachtung der Reihenfolge: n unterschiedbare Elemente:  $n! = n \cdot (n-1) \cdot \dots \cdot 2 \cdot 1$  k Klassen mit je  $n_i$  nicht unterscheidbaren Elementen  $n = \sum_{i=1}^k n_i$ ;  $\frac{n!}{n_1! \cdot n_2! \cdot \dots \cdot n_k!}$

2.5.3 Abzähl k-elementigen Teilmengen einer n-elementigen Menge k-maliges Ziehen aus einer n-elementigen Menge

ohne Zurücklegen =  $k \leq n$ . mit Zurücklegen =  $k > n$  möglich.

mit Beachtung der Reihenfolge, ohne Zurücklegen:  $\frac{n!}{(n-k)!}$

ohne Beachtung der Reihenfolge, ohne Zurücklegen:  $\binom{n}{k} = \frac{n!}{(n-k)! \cdot k!}$

mit Beachtung der Reihenfolge, mit Zurücklegen:  $n^k$


ohne Beachtung der Reihenfolge, mit Zurücklegen:  $\binom{n+k-1}{k}$

2.6 Bedingte Wahrscheinlichkeit

$P(E|F) = P_F(E) = \frac{|E \cap F|}{|F|} = \frac{P(E \cap F)}{P(F)}$

2.6.1 Satz 2.2

$P(E \cap F) = P(E|F) \cdot P(F)$   
 $P(E \cap F) = P(F|E) \cdot P(E)$



2.6.2 Satz der totalen Wahrscheinlichkeit

Sei  $\Omega = \bigcup_{i=1}^n E_i$  mit  $E_i \cap E_j = \emptyset$  für  $i \neq j$  d.h. die Ereignisse bilde eine disjunkte Zerlegung bzw. eine Partition von  $\Omega$ . Somit gilt:

$P(F) = \sum_{i=1}^n P(F \cap E_i) = \sum_{i=1}^n P(F|E_i) \cdot P(E_i)$

Summe der Äste des Wahrscheinlichkeitsbaums zu allen Schnitten  $F \cap E_i$



2.6.3 Vierfeldertafel

$P(F) = P(F \cap E) + P(F \cap \bar{E})$   
 $P(\bar{F}) = P(\bar{F} \cap E) + P(\bar{F} \cap \bar{E})$

	E	$\bar{E}$	
F	$P(F \cap E)$	$P(F \cap \bar{E})$	$P(F)$
$\bar{F}$	$P(\bar{F} \cap E)$	$P(\bar{F} \cap \bar{E})$	$P(\bar{F})$
	$P(E)$	$P(\bar{E})$	1

Satz 2.2  $P(E \cap F)P(E) \cdot P(F|E) = P(F) \cdot P(E|F)$  Tafel  $P(F) - P(F \cap \bar{E}) = P(E) - P(\bar{F} \cap E)$ ;  $P(\bar{F}|E) = 1 - P(F|E)$

2.6.4 Formel von Bayes

Hilfreich, wenn man man  $P(F|E_i)$  kennt, aber nicht  $P(E_k|F)$  Satz 2.4  $P(E_k|F) = \frac{P(F|E_k) \cdot P(E_k)}{\sum_{i=1}^n P(F|E_i) \cdot P(E_i)}$

$$P(E_k|F) = \frac{P(F|E_k) \cdot P(E_k)}{\sum_{i=1}^n P(F|E_i) \cdot P(E_i)}$$

Nur Nenner!  $P(F)$  aus dem Satz der totalen Wahrscheinlichkeit.

2.6.5 Stochastische Unabhängigkeit


Übung Die Ereignisse E und F heißen (stochastisch) unabhängig, wenn die Information über das Eintreten des einen Ereignisses die Wahrscheinlichkeit für das Eintreten des anderen Ereignisses nicht ändert, d.h. falls  $P(E|F) = P(E)$  oder  $P(E \cap F) = P(E) \cdot P(F)$

$= \frac{P(E \cap F)}{P(F)}$

Es gilt Falls die Ereignisse E, F unabhängig sind, dann sind auch:

$E, \bar{F}$   
 $\bar{E}, F$   
 $\bar{E}, \bar{F}$  unabhängig Bemerkung

- Stochastische Unabhängigkeit bedeutet nicht notwendigerweise eine kausale Abhängigkeit
- Veranschaulichung mit Venn Diagramm



- $A, B \neq \emptyset$  und  $A \cap B = \emptyset$   
 $P(A \cap B) \stackrel{?}{=} P(A) \cdot P(B)$   
 $\emptyset \neq P(A) \cdot P(B)$  da  $P(A) > 0$  und  $P(B) > 0$   
 $\Rightarrow A, B$  stochastisch abhängig

3 Zufallsvariable

Abbildung des abstrakten Ergebnisraums  $\Omega$  auf  $\mathbb{R}$ . Eine Abbildung  $X : \Omega \rightarrow \mathbb{R}$ ,  $\omega \mapsto X(\omega)$  heißt Zufallsvariable (ZV).  $x \in \mathbb{R}$  heißt Realisation der ZV X.

- Diskrete ZV:  $X(\Omega) = x_1, \dots, x_2 (n \in \mathbb{N})$ ; z.B.  $X =$  "Augensumme beim Würfeln"
- Stetige ZV:  $X(\Omega) \subseteq \mathbb{R}$ ; "z.B. Körpergröße eines Menschen"

3.1 Verteilungsfunktion-allg.

Die Wahrscheinlichkeit  $P(B)$  für ein Ereignis B in  $\mathbb{R}$  wird zurückgeführt auf die Wahrscheinlichkeit der entsprechenden Ereignisse in  $\Omega$ . Für jedes  $X \in \mathbb{R}$  ist die

Verteilungsfunktion  $F: \mathbb{R} \rightarrow [0,1]$  einer  
ZV  $X$  definiert durch:  
 $F(x) = P(X \leq x)$

- $0 \leq F(x) \leq 1$
- $\lim_{x \rightarrow -\infty} F(x) = 0 \quad \lim_{x \rightarrow \infty} F(x) = 1$
- monoton wachsend
- $P(X > x) = 1 - F(x)$
- $P(a < X \leq b) = F(b) - F(a)$

**3.2 Diskrete ZV**

Für eine diskrete ZV  $X$  mit  $X(\Omega) = x_1, \dots, x_n$  (  $n$  endlich oder abzählbar unendlich) ist die Wahrscheinlichkeitsfunktion definiert durch:

$$p(x) = \begin{cases} P(X = x_i), & \text{falls } x_i \in X(\Omega) \\ 0, & \text{sonst} \end{cases} \quad (2)$$

Es gilt:

- $F(x) = (P(X \leq x) = \sum_{x_i \leq x} p(x_i)$
- $F(x)$  ist eine rechtseitig stetige **Treppenfunktion** mit **Sprüngen** bei der Realisation von  $x_i$ .

**3.3 Stetige ZVs**