# 1 BeschreibendeStatistik

## 1.1 Begriffe

]

### 1.1.1 Beschreibende/Deskriptive Statistik

Beobachtete Daten werden durch geeignete statistische Kennzahlen charakterisiert und durch geeignete Grafiken anschaulich gemacht.

### 1.1.2 Schließende/Induktive Statistik

Aus beobachtete Daten werden Schlüsse gezogen und diese im Rahmen vorgegebener Modelle der Wahrscheinlichkeitstheorie bewertet.

### 1.1.3 Grundgesamtheit

$\Omega$: Grundgesamtheit $\omega$:Element oder Objekt der Grundgesamtheit diskret(<30 Ausprägungen), stetig(≥30 Ausprägungen), univariat(p=1), mulivariat(p>1)

## 1.2 Lagemaße

### 1.2.1 Modalwerte $x_{mod}$

Am häufigsten auftretende Ausprägungen (insbesondere bei **qualitativen** Merkmalen)

### 1.2.2 Mittelwert

R:$mean(x)$
Schwerpunkt der Daten.**Empfindlich**gegemüber Ausreißern.
$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} x_i$

## 1.3 Median

R:$median(x)$
Liegt in der Mitt der sortierten Daten $x_i$. **Unempfindlich** gegenüber Ausreißern.

$$x_{0.5} = \begin{cases} x_{\frac{n+1}{2}}, \text{falls n ungerade} \\ \frac{1}{2}(x_{\frac{n}{2}} + x_{\frac{n}{2}+1}), \text{falls n gerade} \end{cases} \tag{1}$$

## 1.4 Streuungsmaße

### 1.4.1 Spannweite

max $x_i$ - min $x_i$

### 1.4.2 Stichprbenverians $s^2$

R:$var(x)$
**Verschiebungssatz:**
$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x}^2) = \frac{1}{n-1}(\sum_{i=1}^{n} x_i^2 - n\overline{x}^2)$ Gemittelte Summe der quadratischen Abweichung vom Mittelwert

### 1.4.3 Stichprobenstandardabweichung

R:$sd(x)$
$s = \sqrt{s}$ Streuungsmaß mit gleicher Einheit wie beobachteten Daten $x_i$.$\overline{x}$ minimiert die "quadratische Verlustfunktionöder die Varianz gibt das Minimum der Fehlerquadrate an.

## 1.5 p-Quantile

R:$quantile(x,p)$. Teilt die **sortierten** Daten $x_i$ ca. im Verhältnis p: (1-p) d.h. $\hat{F}(x_p) \approx p$ 1. Quartil = 0.25-Quantil; Median = 0.5-Quantil; 3. Quartil = 0.75-Quartil;

## 1.6 Interquartilsabstand I

$I = x_{0.75} - x_{0.25}$. Ist ein weiterer Streuungsparameter.

## 1.7 Chebyshev

$\frac{N(S_k)}{n} > 1 - \frac{1}{k^2}$, für alle k ≥ 1 $\overline{x}$ der Durchschnitt, s > 0 die Stichproben-Standardabweichung von Beobachtungswerten $x_1, ..., x_n$. Sei $S_k = \{i, 1 \leq i \leq n : |x_i - \overline{x}| < k \cdot s\}$; Für eine beliebige Zahl k ≥ 1 liegen mehr als $100 \cdot (1 - \frac{1}{k^2})$ Prozent der Daten im Intervall von $\overline{x} - ks$ bis $\overline{x} + ks$. **Speziell:**Für k = 2 liegen mehr als 75% der Daten im 2s-Bereich um $\overline{x}$. Für k=3 liegen mehr als 89% der Daten im 3s-Bereich um $\overline{x}$. **Komplement Formulierung:** $\overline{S}_k = \{i||x_i - \overline{x}| \geq k \cdot s\}$; $\frac{N(\overline{S}_k)}{n} \leq \frac{1}{k^2}$; Die Ungleichheit lifert nur eine **sehr grobe Abschätzung**, ist aber unabhängig von der Verteilung der Daten. **Empirische Regeln** 68% der Daten im Bereich um $\overline{x} \pm s$. 95% um $\overline{x} \pm 2s$. 99.7% um $\overline{x} \pm 3s$.

## 1.8 Korrelation

Grafische Zusammenhang zwischen multivariaten Daten y und y durch ein Streudiagramm. Kennzahlen zur Untersuchung des Zusammenhangs:

### 1.8.1 Empirische Kovarians

R:$cov(x,y)$; $s_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y}) = \frac{1}{n-1}(\sum_{i=1}^{n}(x_i y_i - n\overline{xy})$

### 1.8.2 Empirische Korrellationskoeffizient r

R:$cor(x,x)$; $r = \frac{s_{xy}}{s_x x_y}$; Näherungsweise lin. Zusammenhang zw. x und y, falls |r| ≈1.

### 1.8.3 Regressionsgerade y

$y = mx + t$ mit $m = r \cdot \frac{s_y}{s_x}$ und $t = \overline{y} - m \cdot \overline{x}$