

## 1 Beschreibende/Deskriptive Statistik

### 1.1 Begriffe

]

#### 1.1.1 Beschreibende/Deskriptive Statistik

Beobachtete Daten werden durch geeignete statistische Kennzahlen charakterisiert und durch geeignete Grafiken anschaulich gemacht.

#### 1.1.2 Schließende/Induktive Statistik

Aus beobachtete Daten werden Schlüsse gezogen und diese im Rahmen vorgegebener Modelle der Wahrscheinlichkeitstheorie bewertet.

#### 1.1.3 Grundgesamtheit

$\Omega$ : Grundgesamtheit  $\omega$ : Element oder Objekt der Grundgesamtheit diskret ( $< 30$  Ausprägungen), stetig ( $\geq 30$  Ausprägungen), univariat ( $p=1$ ), multivariat ( $p>1$ )

### 1.2 Lagemaße

#### 1.2.1 Modalwerte $x_{\text{mod}}$

Am häufigsten auftretende Ausprägungen (insbesondere bei qualitativen Merkmalen)

#### 1.2.2 Mittelwert

R:  $\text{mean}(x)$   
Schwerpunkt der Daten.  
Empfindlich gegenüber Ausreißern.

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$$

#### 1.3 Median

R:  $\text{median}(x)$   
Liegt in der Mitte der sortierten Daten  $x_i$ .  
Unempfindlich gegenüber Ausreißern.

$$x_{0.5} = \begin{cases} x_{\frac{n+1}{2}}, & \text{falls } n \text{ ungerade} \\ \frac{1}{2}(x_{\frac{n}{2}} + x_{\frac{n}{2}+1}), & \text{falls } n \text{ gerade} \end{cases}$$

(1)

#### 1.4 Streuungsmaße

##### 1.4.1 Spannweite

$$\max x_i - \min x_i$$

##### 1.4.2 Stichprobenvarianz $s^2$

R:  $\text{var}(x)$

Verschiebungssatz:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} (\sum_{i=1}^n x_i^2 -$$

$n\bar{x}^2$ ) Gemittelte Summe der quadratischen Abweichung vom Mittelwert

#### 1.4.3 Stichprobenstandardabweichung

R:  $\text{sd}(x)$

$s = \sqrt{s^2}$  Streuungsmaß mit gleicher Einheit wie beobachteten Daten  $x_i$ .  $\bar{x}$  minimiert die "quadratische Verlustfunktion" oder die Varianz gibt das Minimum der Fehlerquadrate an.

#### 1.5 p-Quantile

R:  $\text{quantile}(x, p)$ . Teilt die sortierten Daten  $x_i$  ca. im Verhältnis  $p$ :  $(1-p)$  d.h.  $\hat{F}(x_p) \approx p$ ; 1. Quartil = 0.25-Quantil; Median = 0.5-Quantil; 3. Quartil = 0.75-Quantil;

#### 1.6 Interquartilsabstand I

$I = x_{0.75} - x_{0.25}$ . Ist ein weiterer Streuungsparameter.

#### 1.7 Chebyshev

$\frac{N(S_k)}{n} > 1 - \frac{1}{k^2}$ , für alle  $k \geq 1$   $\bar{x}$  der Durchschnitt,  $s > 0$  die Stichproben-Standardabweichung von Beobachtungswerten  $x_1, \dots, x_n$ . Sei  $S_k = \{i, 1 \leq i \leq n : |x_i - \bar{x}| < k \cdot s\}$ ; Für eine beliebige Zahl  $k \geq 1$  liegen mehr als  $100 \cdot (1 - \frac{1}{k^2})$  Prozent der Daten im Intervall von  $\bar{x} - ks$  bis  $\bar{x} + ks$ . Speziell: Für  $k=2$  liegen mehr als 75% der Daten im 2s-Bereich um  $\bar{x}$ . Für  $k=3$  liegen mehr als 89% der Daten im 3s-Bereich um  $\bar{x}$ . Komplement Formulierung:  $\bar{S}_k = \{i || x_i - \bar{x}| \geq k \cdot s\}$ ;  $\frac{N(\bar{S}_k)}{n} \leq \frac{1}{k^2}$ ;

Die Ungleichheit liefert nur eine sehr grobe Abschätzung, ist aber unabhängig von der Verteilung der Daten. Empirische Regeln 68% der Daten im Bereich um  $\bar{x} \pm s$ . 95% um  $\bar{x} \pm 2s$ . 99.7% um  $\bar{x} \pm 3s$ .

#### 1.8 Korrelation

Grafische Zusammenhang zwischen multivariaten Daten  $x$  und  $y$  durch ein Streudiagramm. Kennzahlen zur Untersuchung des Zusammenhangs:

##### 1.8.1 Empirische Kovarians

$$R: \text{cov}(x, y); s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n-1} (\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y})$$

##### 1.8.2 Empirische Korrelationskoeffizient r

R:  $\text{cor}(x, x)$ ;  $r = \frac{s_{xy}}{s_x s_y}$ ; Näherungsweise lin. Zusammenhang zw.  $x$  und  $y$ , falls  $|r| \approx 1$ .

##### 1.8.3 Regressionsgerade y

$$y = mx + t \text{ mit } m = r \cdot \frac{s_y}{s_x} \text{ und } t = \bar{y} - m \cdot \bar{x}$$

## 2 Wahrscheinlichkeitsrechnung

### 2.1 Begriffe

Ergebnisraum  $\Omega$ : Menge aller möglichen Ergebnisse eines Experiments

Elementarereignis  $\omega \in \Omega$ : einzelnes Element von  $\Omega$

Ereignis  $E \subseteq \Omega$ : beliebige Teilmenge des Ergebnisraums  $\Omega$  heißt sicheres Ereignis,  $\emptyset$  heißt unmögliches Ereignis

Vereinigung  $E \cup F$ : Ereignis E oder Ereignis F treten ein.  $\bigcup_{i=1}^n E_i$ : mindestens ein Ereignis  $E_i$  tritt ein.

Schnitt  $E \cap F$ : Ereignis E und Ereignis F treten ein.

$\bigcap_{i=1}^n E_i$  alle Ereignisse  $E_i$  treten ein. Gegenereignis  $\bar{E} = \Omega / E$ : Ereignis E tritt nicht ein (Komplement von E)

Disjunkte Ereignisse E und F:  $E \cap F = \emptyset$

### 2.2 De Morgan'schen Regeln

$$\overline{E_1 \cup E_2} = \bar{E}_1 \cap \bar{E}_2$$

$$\overline{E_1 \cap E_2} = \bar{E}_1 \cup \bar{E}_2$$

### 2.3 Wahrscheinlichkeit

$$0 \leq P(E) \leq 1; P(\Omega) = 1;$$

$$P(\bigcup_{i=1}^{\infty} E_i) = \sum_{i=1}^{\infty} P(E_i), \text{ falls } E_i \cap E_j = \emptyset \text{ für } i \neq j$$

#### 2.3.1 Satz 2.1

$$P(\bar{E}) = 1 - P(E)$$

$$P(E \cup F) = P(E) + P(F) - P(E \cap F)$$

(Übungsaufgabe!!! Ergänzen)

### 2.4 Laplace-Experiment

Zufallsexperimente mit  $n$  gleich wahrscheinlichen Elementarereignissen. Dann berechnet sich die Wahrscheinlichkeit  $P(E)$  für  $E \subseteq \Omega$  aus:

$$P(E) = \frac{\text{Anzahl der für } E \text{ günstigen Ereignisse}}{\text{Anzahl der möglichen Ereignisse}} = \frac{\text{Mächtigkeit von } E}{\text{Mächtigkeit von } \Omega} = \frac{|E|}{|\Omega|} \text{ text}$$

### 2.5 Kombinatorik

#### 2.5.1 Allgemeines Zählprinzip

Anzahl der Möglichkeiten für ein  $k$ -stufes Zufallsexperiment mit  $n_i$  Varianten im  $i$ -ten Schritt:  $n_1 \cdot n_2 \cdot \dots \cdot n_k$

#### 2.5.2 Permutationen

Anzahl einer  $n$ -elementigen Menge  $n$ -maliges Ziehen ohne Zurücklegen mit Beachtung der Reihenfolge:  $n$  unterscheidbare Elemente:  $n! = n \cdot (n-1) \cdot \dots \cdot 2 \cdot 1$   $k$  Klassen mit je  $n_i$  nicht unterscheidbaren Elementen  $n = \sum_{i=1}^k n_i$ ;  $\frac{n!}{n_1! \cdot n_2! \cdot \dots \cdot n_k!}$

### 2.5.3 Abzähl k-elementigen Teilmengen einer n-elementigen Menge k-maliges Ziehen aus einer n-elementigen Menge

ohne Zurücklegen =  $k \leq n$ .

mit Zurücklegen =  $k > n$  möglich.

mit Beachtung der Reihenfolge, ohne

Zurücklegen:  $\frac{n!}{(n-k)!}$

ohne Beachtung der Reihenfolge, ohne

Zurücklegen:  $\binom{n}{k} = \frac{n!}{(n-k)!k!}$

mit Beachtung der Reihenfolge, mit Zurücklegen:  $n^k$

ohne Beachtung der Reihenfolge, mit Zurücklegen:  $\binom{n+k-1}{k}$

### 2.6 Bedingte Wahrscheinlichkeit

$$P(E|F) = P_F(E) = \frac{|E \cap F|}{|F|} = \frac{P(E \cap F)}{P(F)}$$

$$P(E \cap F) = P(F) \cdot P(E|F)$$

$$P(E \cap F) = P(F|E) \cdot P(E)$$


$$P(E|F) = \frac{P(E \cap F)}{P(F)}$$

$$P(F|E) = \frac{P(E \cap F)}{P(E)}$$

#### 2.6.1 Satz 2.2

$$P(E \cap F) = P(E|F) \cdot P(F)$$

$$P(E \cap F) = P(F|E) \cdot P(E)$$




#### 2.6.2 Satz der totalen Wahrscheinlichkeit

Sei  $\Omega = \bigcup_{i=1}^n E_i$  mit  $E_i \cap E_j = \emptyset$  für  $i \neq j$  d.h. die Ereignisse bilde eine disjunkte Zerlegung bzw. eine Partition von  $\Omega$ . Somit gilt:

$$P(F) = \sum_{i=1}^n P(F \cap E_i) = \sum_{i=1}^n P(F|E_i) \cdot P(E_i)$$

Summe der Äste des Wahrscheinlichkeitsbaums zu allen Schnitten  $F \cap E_i$



#### 2.6.3 Vierfeldertafel

$$P(F) = P(F \cap E) + P(F \cap \bar{E})$$

$$P(\bar{F}) = P(\bar{F} \cap E) + P(\bar{F} \cap \bar{E})$$

	E	$\bar{E}$	
F	$P(F \cap E)$	$P(F \cap \bar{E})$	$P(F)$
$\bar{F}$	$P(\bar{F} \cap E)$	$P(\bar{F} \cap \bar{E})$	$P(\bar{F})$
	$P(E)$	$P(\bar{E})$	1

Satz 2.2  $P(E \cap F) = P(E) \cdot P(F|E)$   $P(F|E) = \frac{P(E \cap F)}{P(E)}$   $P(F) = P(F|E) \cdot P(E) + P(F|\bar{E}) \cdot P(\bar{E})$   $P(F|\bar{E}) = \frac{P(\bar{E} \cap F)}{P(\bar{E})}$   $P(\bar{F}|E) = 1 - P(F|E)$

### 2.6.4 Formel von Bayes

Hilfreich, wenn man man  $P(F|E_i)$  kennt, aber nicht  $P(E_k|F)$  Satz 2.4  $P(E_k|F) = \frac{P(F|E_k) \cdot P(E_k)}{\sum_{i=1}^n P(F|E_i) \cdot P(E_i)}$

$$P(E_k|F) = \frac{P(F|E_k) \cdot P(E_k)}{\sum_{i=1}^n P(F|E_i) \cdot P(E_i)}$$

Nur Nenner!  $P(F)$  aus dem Satz der totalen Wahrscheinlichkeit.

#### 2.6.5 Stochastische Unabhängigkeit

Übung Die Ereignisse E und F heißen (stochastisch) unabhängig, wenn die Information über das Eintreten des einen Ereignisses die Wahrscheinlichkeit für das Eintreten des anderen Ereignisses nicht ändert, d.h. falls  $P(E|F) = P(E)$  oder  $P(E \cap F) = P(E) \cdot P(F)$

$$P(E|F) = \frac{P(E \cap F)}{P(F)}$$

$$P(E) = \frac{P(E \cap F)}{P(F)}$$

Es gilt Falls die Ereignisse E, F unabhängig sind, dann sind auch:


$$E, \bar{F}$$

$$\bar{E}, F$$

$$\bar{E}, \bar{F}$$

unabhängig Bemerkung

- Stochastische Unabhängigkeit bedeutet nicht notwendigerweise eine kausale Abhängigkeit
- Veranschaulichung mit Venn Diagramm



stoch. unabhängig  $P(E) = \frac{1}{2} = P(F)$   $P(F) = \frac{1}{2} < P(E|F)$

- $A, B \neq \emptyset$  und  $A \cap B = \emptyset$   $P(A \cap B) \stackrel{?}{=} P(A) \cdot P(B)$   $\emptyset \neq P(A) \cdot P(B)$  da  $P(A) > 0$  und  $P(B) > 0$   $\Rightarrow A, B$  stochastisch abhängig

### 3 Zufallsvariable

Abbildung des abstrakten Ergebnisraums  $\Omega$  auf  $\mathbb{R}$ . Eine Abbildung  $X: \Omega \rightarrow \mathbb{R}$ ,  $\omega \mapsto X(\omega)$  heißt Zufallsvariable (ZV).  $x \in \mathbb{R}$  heißt Realisation der ZV  $X$ .

- Diskrete ZV:  $X(\Omega) = x_1, \dots, x_2 (n \in \mathbb{N})$ ; z.B.  $X$  = "Augensumme beim Würfeln"
- Stetige ZV:  $X(\Omega) \subseteq \mathbb{R}$ ; z.B. Körpergröße eines Menschen"


#### 3.1 Verteilungsfunktion-allg.

Die Wahrscheinlichkeit  $P(B)$  für ein Ereignis B in  $\mathbb{R}$  wird zurückgeführt auf die Wahrscheinlichkeit der entsprechenden Ereignisse in  $\Omega$ . Für jedes  $X \in \mathbb{R}$  ist die




#### 4.2.4 Exponentialverteilung

Modellierung von Lebensdauern, Wartezeiten Sei  $Y_t \sim P_{\lambda t}$  im Intervall  $[0, t]$  von  $t$  Zeiteinheiten, dann beschreibt die Exponentialverteilung die Wartezeit  $X$  bis zum Eintreten eines Ereignisses; **Dichte- und Verteilungsfunktion:**  $f(x) = \lambda e^{-\lambda x} (x \geq 0)$  und  $F(x) = 1 - e^{-\lambda x}$ ; **Verteilung:**  $X \sim Exp_{\lambda}$ ;  $E[X] = \frac{1}{\lambda} \Rightarrow$  Berechnung mit partieller Integration;  $Var[X] = \frac{1}{\lambda^2}$ ; **R:**  $dexp(x, \lambda) = f(x)$ ;  $pexp(x, \lambda) = F(x)$ ; **Eigenschaft:** Eine exponentialverteilte ZV  $X$  ist gedächtnislos, d.h.  $P(X > s + t) | X > t = P(X > s)$ ;



#### 4.2.5 Chiquadrat-Verteilung

$Z_1, \dots, Z_n$  seien unabhängige, standard-normalverteilte ZV  $\Rightarrow X = Z_1^2 + \dots + Z_n^2$  hat Chiquadratverteilung mit n Freiheitsgraden; **Anwendungsmodell:** Summen unabhängiger, standardnormalverteilter ZV; **Verteilung:**  $X \sim \chi_n^2$ ;  $E[X] = n$ ;  $Var[X] = 2n$ ; **R:**  $dchisq(x, n) = f(x)$ ;  $pchisq(x, n) = F(x)$ ; **Eigenschaft:**  $X_1 \sim \chi_{n_1}^2$  und  $X_2 \sim \chi_{n_2}^2 \Rightarrow X_1 + X_2 \sim \chi_{n_1+n_2}^2$



#### 4.2.6 t-Verteilung

$Z \sim N_{0,1}$  und  $X \sim \chi_n^2 \Rightarrow Y = \frac{Z}{\sqrt{X/n}}$  ist t-verteilt mit n Freiheitsgraden; **Anwendungsmodell:** Schätz- und Testverfahren bei unbekannter Varianz; **Verteilung:**  $Y \sim t_n$ ;  $E[Y] = 0$  für  $n > 1$ ;  $Var[Y] = \frac{n}{n-2}$  für  $n > 2$ ; **R:**  $dt(y, n) \hat{=} f(x)$ ;  $pt(y, n) \hat{=} F(x)$ ; **Eigenschaften:** Für  $n \rightarrow \infty : t_n \rightarrow N_{0,1}$ ; Achsensymmetrie der Dichtefunktion  $\Rightarrow -y_p = x_{1-p}$




Abbildung Dichtefunktion